

Tarea 6

Juan M Karawcki, Bruno Pintos

2025-09-22

Ejercicio 6.7 (Aproximación por grilla Normal-Normal)

Consideremos el modelo Normal–Normal para μ con

$$Y_i \mid \mu \sim N(\mu, 1.3^2)$$

y

$$\mu \sim N(10, 1.2^2)$$

Supongamos que en $n = 4$ observaciones independientes se obtienen los datos:

$$(Y_1, Y_2, Y_3, Y_4) = (7.1, 8.9, 8.4, 8.6)$$

1. Utiliza la aproximación por grilla con valores de

$$\mu \in \{5, 6, 7, \dots, 15\}$$

para aproximar el modelo posterior de μ .

```
# PASO 1: Definir una grilla de 11 valores de mu
grid_data <- data.frame(mu_grid = seq(from = 5, to = 15, by = 1))
y <- c(7.1, 8.9, 8.4, 8.6)

# PASO 2: Evaluar la priori y la verosimilitud para cada valor de mu

grid_data <- grid_data %>%
  mutate(
    prior = dnorm(mu_grid, 10, 1.2),
    # Priori: distribución normal(10, 1.2**2)
    likelihood = sapply(mu_grid, function(m) prod(dnorm(y, mean = m, sd = 1.3)))
    # Verosimilitud:
  )

# PASO 3: Aproximación de la distribución a posteriori (no normalizada y normalizada)
grid_data <- grid_data %>%
  mutate(
    unnormalized = likelihood * prior,
```

```

# Producto prior * verosimilitud
posterior = unnormalized / sum(unnormalized)
# Normalización para que sume 1
)

```

```


# Verificar que la suma de las probabilidades que
# definen la aproximación computacional de la
# distribución a posteriori normalizada es 1
grid_data %>%
  summarize(sum(unnormalized), sum(posterior))

```

```

##      sum(unnormalized) sum(posterior)
## 1          0.00105926              1

```



2. Repite la parte (a) usando una grilla de 201 valores igualmente espaciados entre 5 y 15.

```

# PASO 1: Definir una grilla de 11 valores de mu
grid_data <- data.frame(mu_grid = seq(from = 5, to = 15, length.out = 201))
y <- c(7.1, 8.9, 8.4, 8.6)

```

```

# PASO 2: Evaluar la priori y la verosimilitud para cada valor de mu

grid_data <- grid_data %>%
  mutate(
    prior = dnorm(mu_grid, 10, 1.2),
    # Priori: distribución normal(10, 1.2**2)
    likelihood = sapply(mu_grid, function(m) prod(dnorm(y, mean = m, sd = 1.3)))
    # Verosimilitud:
  )

```

```

# PASO 3: Aproximación de la distribución a posteriori (no normalizada y normalizada)
grid_data <- grid_data %>%

```

```

mutate(
  unnormalized = likelihood * prior,
  # Producto prior * verosimilitud
  posterior = unnormalized / sum(unnormalized)
  # Normalización para que sume 1
)

# Verificar que la suma de las probabilidades que
# definen la aproximación computacional de la
# distribución a posteriori normalizada es 1
grid_data %>%
  summarize(sum(unnormalized), sum(posterior))

##      sum(unnormalized) sum(posterior)
## 1          0.02122574             1

# Examinar la tabla resultante con la aproximación por grilla
round(grid_data, 5)

##      mu_grid  prior likelihood unnormalized posterior
## 1      5.00 0.00006   0.00000      0.00000  0.00000
## 2      5.05 0.00007   0.00000      0.00000  0.00000
## 3      5.10 0.00008   0.00000      0.00000  0.00000
## 4      5.15 0.00009   0.00000      0.00000  0.00000
## 5      5.20 0.00011   0.00000      0.00000  0.00000
## 6      5.25 0.00013   0.00000      0.00000  0.00000
## 7      5.30 0.00016   0.00000      0.00000  0.00000
## 8      5.35 0.00018   0.00000      0.00000  0.00000
## 9      5.40 0.00021   0.00000      0.00000  0.00000
## 10     5.45 0.00025   0.00000      0.00000  0.00000
## 11     5.50 0.00029   0.00000      0.00000  0.00000
## 12     5.55 0.00034   0.00000      0.00000  0.00000
## 13     5.60 0.00040   0.00000      0.00000  0.00000
## 14     5.65 0.00047   0.00000      0.00000  0.00000
## 15     5.70 0.00054   0.00000      0.00000  0.00000
## 16     5.75 0.00063   0.00000      0.00000  0.00000
## 17     5.80 0.00073   0.00000      0.00000  0.00000
## 18     5.85 0.00084   0.00001      0.00000  0.00000
## 19     5.90 0.00097   0.00001      0.00000  0.00000
## 20     5.95 0.00112   0.00001      0.00000  0.00000
## 21     6.00 0.00129   0.00001      0.00000  0.00000
## 22     6.05 0.00148   0.00002      0.00000  0.00000
## 23     6.10 0.00169   0.00002      0.00000  0.00000
## 24     6.15 0.00193   0.00003      0.00000  0.00000
## 25     6.20 0.00221   0.00004      0.00000  0.00000
## 26     6.25 0.00252   0.00004      0.00000  0.00001
## 27     6.30 0.00287   0.00006      0.00000  0.00001
## 28     6.35 0.00326   0.00007      0.00000  0.00001
## 29     6.40 0.00369   0.00009      0.00000  0.00002
## 30     6.45 0.00418   0.00011      0.00000  0.00002
## 31     6.50 0.00473   0.00014      0.00000  0.00003
## 32     6.55 0.00533   0.00017      0.00000  0.00004

```

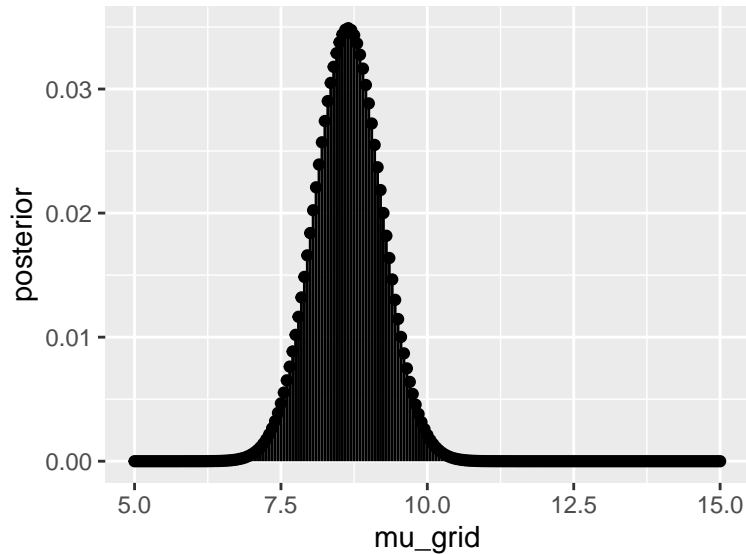
## 33	6.60	0.00601	0.00020	0.00000	0.00006
## 34	6.65	0.00675	0.00025	0.00000	0.00008
## 35	6.70	0.00758	0.00030	0.00000	0.00011
## 36	6.75	0.00849	0.00035	0.00000	0.00014
## 37	6.80	0.00950	0.00042	0.00000	0.00019
## 38	6.85	0.01060	0.00050	0.00001	0.00025
## 39	6.90	0.01182	0.00059	0.00001	0.00033
## 40	6.95	0.01315	0.00069	0.00001	0.00043
## 41	7.00	0.01461	0.00080	0.00001	0.00055
## 42	7.05	0.01620	0.00092	0.00001	0.00070
## 43	7.10	0.01793	0.00106	0.00002	0.00090
## 44	7.15	0.01981	0.00121	0.00002	0.00113
## 45	7.20	0.02185	0.00138	0.00003	0.00142
## 46	7.25	0.02406	0.00155	0.00004	0.00176
## 47	7.30	0.02645	0.00174	0.00005	0.00217
## 48	7.35	0.02902	0.00194	0.00006	0.00266
## 49	7.40	0.03179	0.00216	0.00007	0.00323
## 50	7.45	0.03477	0.00238	0.00008	0.00389
## 51	7.50	0.03795	0.00261	0.00010	0.00466
## 52	7.55	0.04136	0.00284	0.00012	0.00553
## 53	7.60	0.04499	0.00308	0.00014	0.00652
## 54	7.65	0.04886	0.00331	0.00016	0.00762
## 55	7.70	0.05297	0.00354	0.00019	0.00885
## 56	7.75	0.05732	0.00377	0.00022	0.01019
## 57	7.80	0.06193	0.00399	0.00025	0.01164
## 58	7.85	0.06678	0.00420	0.00028	0.01320
## 59	7.90	0.07190	0.00439	0.00032	0.01486
## 60	7.95	0.07727	0.00456	0.00035	0.01659
## 61	8.00	0.08290	0.00471	0.00039	0.01839
## 62	8.05	0.08878	0.00484	0.00043	0.02023
## 63	8.10	0.09492	0.00494	0.00047	0.02208
## 64	8.15	0.10130	0.00501	0.00051	0.02391
## 65	8.20	0.10793	0.00506	0.00055	0.02571
## 66	8.25	0.11479	0.00507	0.00058	0.02742
## 67	8.30	0.12188	0.00506	0.00062	0.02903
## 68	8.35	0.12918	0.00501	0.00065	0.03049
## 69	8.40	0.13668	0.00494	0.00067	0.03179
## 70	8.45	0.14436	0.00484	0.00070	0.03289
## 71	8.50	0.15221	0.00471	0.00072	0.03377
## 72	8.55	0.16021	0.00456	0.00073	0.03440
## 73	8.60	0.16833	0.00439	0.00074	0.03478
## 74	8.65	0.17656	0.00420	0.00074	0.03490
## 75	8.70	0.18488	0.00399	0.00074	0.03475
## 76	8.75	0.19325	0.00377	0.00073	0.03434
## 77	8.80	0.20164	0.00354	0.00071	0.03367
## 78	8.85	0.21004	0.00331	0.00070	0.03277
## 79	8.90	0.21841	0.00308	0.00067	0.03164
## 80	8.95	0.22671	0.00284	0.00064	0.03032
## 81	9.00	0.23493	0.00261	0.00061	0.02884
## 82	9.05	0.24302	0.00238	0.00058	0.02722
## 83	9.10	0.25095	0.00216	0.00054	0.02549
## 84	9.15	0.25869	0.00194	0.00050	0.02369
## 85	9.20	0.26621	0.00174	0.00046	0.02185
## 86	9.25	0.27347	0.00155	0.00042	0.02000

## 87	9.30	0.28044	0.00138	0.00039	0.01817
## 88	9.35	0.28709	0.00121	0.00035	0.01638
## 89	9.40	0.29339	0.00106	0.00031	0.01465
## 90	9.45	0.29930	0.00092	0.00028	0.01301
## 91	9.50	0.30481	0.00080	0.00024	0.01146
## 92	9.55	0.30988	0.00069	0.00021	0.01002
## 93	9.60	0.31449	0.00059	0.00018	0.00869
## 94	9.65	0.31861	0.00050	0.00016	0.00748
## 95	9.70	0.32222	0.00042	0.00014	0.00639
## 96	9.75	0.32531	0.00035	0.00012	0.00542
## 97	9.80	0.32787	0.00030	0.00010	0.00456
## 98	9.85	0.32986	0.00025	0.00008	0.00381
## 99	9.90	0.33130	0.00020	0.00007	0.00316
## 100	9.95	0.33216	0.00017	0.00006	0.00260
## 101	10.00	0.33245	0.00014	0.00004	0.00212
## 102	10.05	0.33216	0.00011	0.00004	0.00172
## 103	10.10	0.33130	0.00009	0.00003	0.00138
## 104	10.15	0.32986	0.00007	0.00002	0.00110
## 105	10.20	0.32787	0.00006	0.00002	0.00087
## 106	10.25	0.32531	0.00004	0.00001	0.00068
## 107	10.30	0.32222	0.00004	0.00001	0.00053
## 108	10.35	0.31861	0.00003	0.00001	0.00041
## 109	10.40	0.31449	0.00002	0.00001	0.00032
## 110	10.45	0.30988	0.00002	0.00001	0.00024
## 111	10.50	0.30481	0.00001	0.00000	0.00018
## 112	10.55	0.29930	0.00001	0.00000	0.00014
## 113	10.60	0.29339	0.00001	0.00000	0.00010
## 114	10.65	0.28709	0.00001	0.00000	0.00008
## 115	10.70	0.28044	0.00000	0.00000	0.00006
## 116	10.75	0.27347	0.00000	0.00000	0.00004
## 117	10.80	0.26621	0.00000	0.00000	0.00003
## 118	10.85	0.25869	0.00000	0.00000	0.00002
## 119	10.90	0.25095	0.00000	0.00000	0.00001
## 120	10.95	0.24302	0.00000	0.00000	0.00001
## 121	11.00	0.23493	0.00000	0.00000	0.00001
## 122	11.05	0.22671	0.00000	0.00000	0.00001
## 123	11.10	0.21841	0.00000	0.00000	0.00000
## 124	11.15	0.21004	0.00000	0.00000	0.00000
## 125	11.20	0.20164	0.00000	0.00000	0.00000
## 126	11.25	0.19325	0.00000	0.00000	0.00000
## 127	11.30	0.18488	0.00000	0.00000	0.00000
## 128	11.35	0.17656	0.00000	0.00000	0.00000
## 129	11.40	0.16833	0.00000	0.00000	0.00000
## 130	11.45	0.16021	0.00000	0.00000	0.00000
## 131	11.50	0.15221	0.00000	0.00000	0.00000
## 132	11.55	0.14436	0.00000	0.00000	0.00000
## 133	11.60	0.13668	0.00000	0.00000	0.00000
## 134	11.65	0.12918	0.00000	0.00000	0.00000
## 135	11.70	0.12188	0.00000	0.00000	0.00000
## 136	11.75	0.11479	0.00000	0.00000	0.00000
## 137	11.80	0.10793	0.00000	0.00000	0.00000
## 138	11.85	0.10130	0.00000	0.00000	0.00000
## 139	11.90	0.09492	0.00000	0.00000	0.00000
## 140	11.95	0.08878	0.00000	0.00000	0.00000

## 141	12.00	0.08290	0.00000	0.00000	0.00000
## 142	12.05	0.07727	0.00000	0.00000	0.00000
## 143	12.10	0.07190	0.00000	0.00000	0.00000
## 144	12.15	0.06678	0.00000	0.00000	0.00000
## 145	12.20	0.06193	0.00000	0.00000	0.00000
## 146	12.25	0.05732	0.00000	0.00000	0.00000
## 147	12.30	0.05297	0.00000	0.00000	0.00000
## 148	12.35	0.04886	0.00000	0.00000	0.00000
## 149	12.40	0.04499	0.00000	0.00000	0.00000
## 150	12.45	0.04136	0.00000	0.00000	0.00000
## 151	12.50	0.03795	0.00000	0.00000	0.00000
## 152	12.55	0.03477	0.00000	0.00000	0.00000
## 153	12.60	0.03179	0.00000	0.00000	0.00000
## 154	12.65	0.02902	0.00000	0.00000	0.00000
## 155	12.70	0.02645	0.00000	0.00000	0.00000
## 156	12.75	0.02406	0.00000	0.00000	0.00000
## 157	12.80	0.02185	0.00000	0.00000	0.00000
## 158	12.85	0.01981	0.00000	0.00000	0.00000
## 159	12.90	0.01793	0.00000	0.00000	0.00000
## 160	12.95	0.01620	0.00000	0.00000	0.00000
## 161	13.00	0.01461	0.00000	0.00000	0.00000
## 162	13.05	0.01315	0.00000	0.00000	0.00000
## 163	13.10	0.01182	0.00000	0.00000	0.00000
## 164	13.15	0.01060	0.00000	0.00000	0.00000
## 165	13.20	0.00950	0.00000	0.00000	0.00000
## 166	13.25	0.00849	0.00000	0.00000	0.00000
## 167	13.30	0.00758	0.00000	0.00000	0.00000
## 168	13.35	0.00675	0.00000	0.00000	0.00000
## 169	13.40	0.00601	0.00000	0.00000	0.00000
## 170	13.45	0.00533	0.00000	0.00000	0.00000
## 171	13.50	0.00473	0.00000	0.00000	0.00000
## 172	13.55	0.00418	0.00000	0.00000	0.00000
## 173	13.60	0.00369	0.00000	0.00000	0.00000
## 174	13.65	0.00326	0.00000	0.00000	0.00000
## 175	13.70	0.00287	0.00000	0.00000	0.00000
## 176	13.75	0.00252	0.00000	0.00000	0.00000
## 177	13.80	0.00221	0.00000	0.00000	0.00000
## 178	13.85	0.00193	0.00000	0.00000	0.00000
## 179	13.90	0.00169	0.00000	0.00000	0.00000
## 180	13.95	0.00148	0.00000	0.00000	0.00000
## 181	14.00	0.00129	0.00000	0.00000	0.00000
## 182	14.05	0.00112	0.00000	0.00000	0.00000
## 183	14.10	0.00097	0.00000	0.00000	0.00000
## 184	14.15	0.00084	0.00000	0.00000	0.00000
## 185	14.20	0.00073	0.00000	0.00000	0.00000
## 186	14.25	0.00063	0.00000	0.00000	0.00000
## 187	14.30	0.00054	0.00000	0.00000	0.00000
## 188	14.35	0.00047	0.00000	0.00000	0.00000
## 189	14.40	0.00040	0.00000	0.00000	0.00000
## 190	14.45	0.00034	0.00000	0.00000	0.00000
## 191	14.50	0.00029	0.00000	0.00000	0.00000
## 192	14.55	0.00025	0.00000	0.00000	0.00000
## 193	14.60	0.00021	0.00000	0.00000	0.00000
## 194	14.65	0.00018	0.00000	0.00000	0.00000

```
## 195 14.70 0.00016 0.00000 0.00000 0.00000
## 196 14.75 0.00013 0.00000 0.00000 0.00000
## 197 14.80 0.00011 0.00000 0.00000 0.00000
## 198 14.85 0.00009 0.00000 0.00000 0.00000
## 199 14.90 0.00008 0.00000 0.00000 0.00000
## 200 14.95 0.00007 0.00000 0.00000 0.00000
## 201 15.00 0.00006 0.00000 0.00000 0.00000
```

```
# Devuelve una tabla con las columnas: pi_grid, prior, likelihood, unnormalized, posterior
```



Ejercicio 6.15 (MCMC con RStan: Gamma–Poisson)

Consideremos el modelo Gamma–Poisson para λ con

$$Y_i \mid \lambda \sim \text{Pois}(\lambda) \quad \text{y} \quad \lambda \sim \text{Gamma}(20, 5),$$

donde usamos la parametrización **Gamma(shape, rate)**. Observamos $n = 3$ datos independientes

$$(Y_1, Y_2, Y_3) = (0, 1, 0).$$

Objetivo

- Simular el modelo a posteriori de λ con **RStan** usando **4 cadenas** y **10 000 iteraciones por cadena**.
- Producir *trace plots* y densidades para las cuatro cadenas.
- A partir de las densidades, indicar el valor de λ más plausible a posteriori.
- Especificar el modelo a posteriori de λ por conjugación y comparar con la aproximación MCMC.

```
# Técnica de aproximación (MCMC) de la posteriori
# Produce cadenas dependientes de lambda a partir del modelo Gamma-Poisson.

# Ejemplo Gamma-Poisson
```

```
#
# PASO 1: Definición de la estructura del modelo bayesiano
gp_model <- "
data {
  int<lower=0> N;          // número de observaciones
  int<lower=0> y[N];       // datos Poisson
  real<lower=0> alpha;     // shape de la Gamma prior
  real<lower=0> beta;      // rate de la Gamma prior
}
parameters {
  real<lower=0> lambda;    // parámetro Poisson
}
model {
  lambda ~ gamma(alpha, beta); // prior Gamma(shape, rate)
  y ~ poisson(lambda);        // verosimilitud
}
"
```

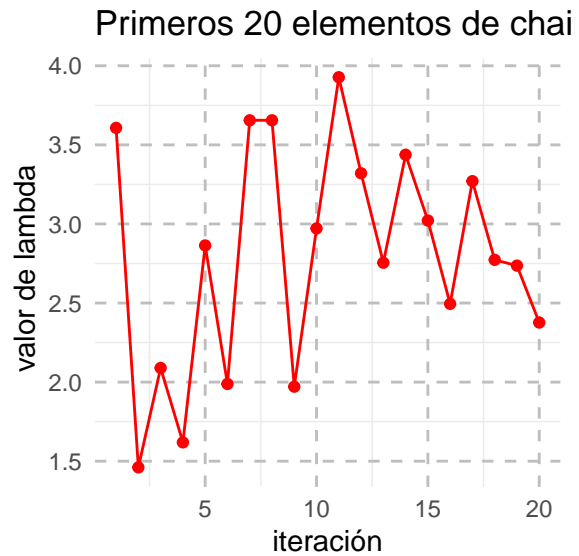

```
# Datos y prior
y <- c(0L, 1L, 0L)
N <- length(y)
alpha <- 20
beta <- 5
```

```
# PASO 2: Simulación de la distribución a posteriori con rstan::stan()
gp_sim <- stan(
  model_code = gp_model,
  data = list(N = N, y = y, alpha = alpha, beta = beta),
  chains = 4, iter = 10000, warmup = 1000, seed = 84735
)
```


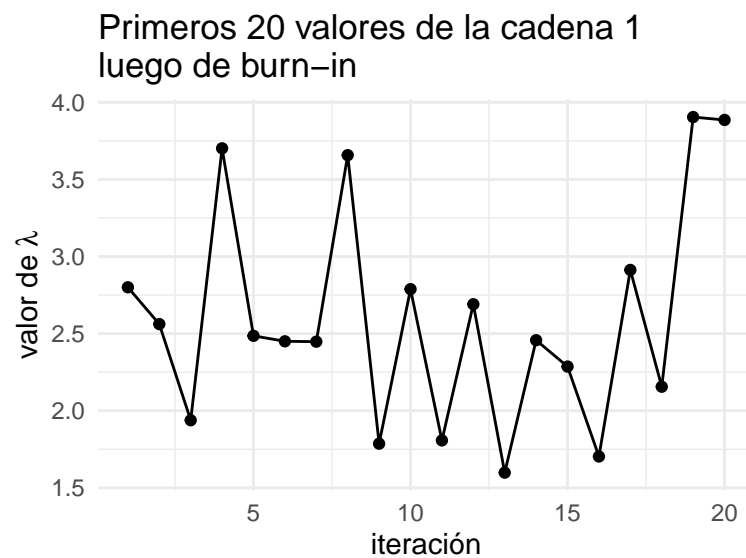
```
# Visualización de los primeros cuatro valores de las realizaciones de cada cadena
as.array(gp_sim, pars = "lambda") %>% head(4)
```

```
## , , parameters = lambda
##
##           chains
## iterations chain:1 chain:2 chain:3 chain:4
##      [1,] 2.058805 2.953002 3.607447 3.039642
##      [2,] 3.076931 2.764217 1.460747 2.048070
##      [3,] 3.076931 2.764217 2.089549 1.884896
##      [4,] 2.387108 3.041081 1.618826 1.943340
```


```
# Extraer los primeros 20 elementos de chain:1 y chain:3
samples_array <- as.array(gp_sim, pars = "lambda")
chain_1 <- samples_array[1:20, 1, 1]
chain_3 <- samples_array[1:20, 3, 1]
```

```
## num [1:36000(1d)] 2.8 2.56 1.94 3.7 2.49 ...
## - attr(*, "dimnames")=List of 1
## ..$ iterations: NULL
```

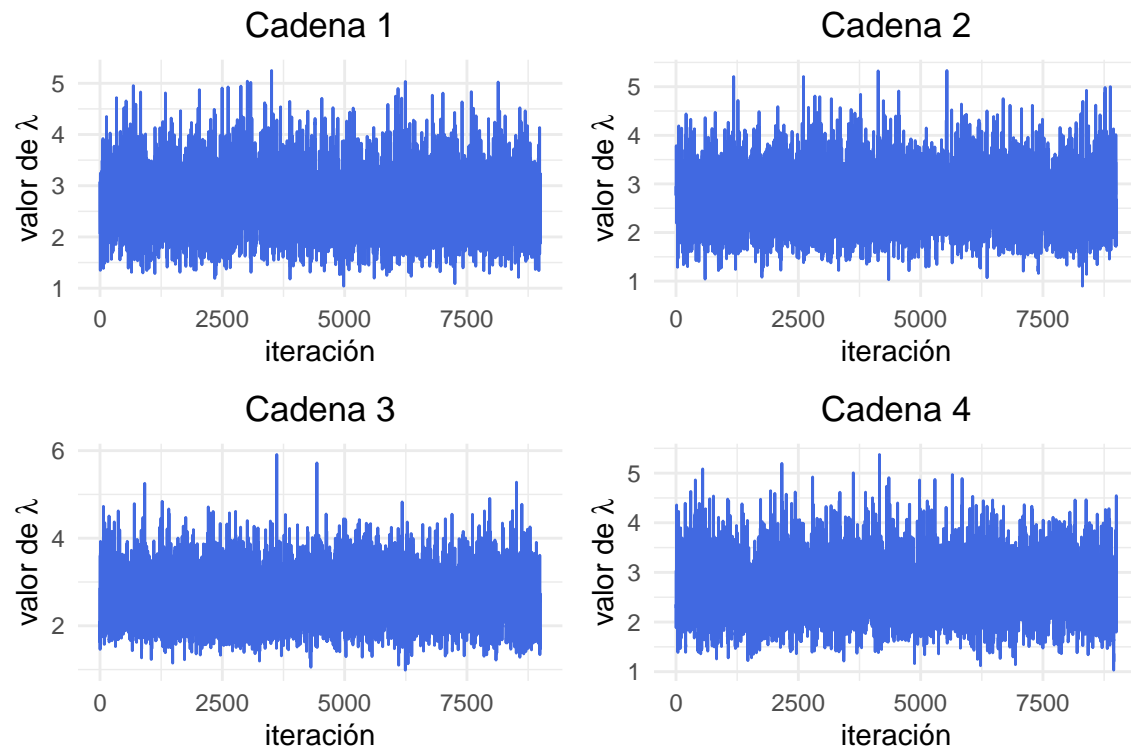


```
# Trazas de las cuatro cadenas de Markov para lambda
mcmc_trace(gp_sim, pars = "lambda", size = 0.1)
```





```
# Extraer todas las cadenas completas (array)
samples_array <- as.array(gp_sim, pars = "lambda")
chain_1 <- samples_array[, 1, 1]
chain_2 <- samples_array[, 2, 1]
chain_3 <- samples_array[, 3, 1]
chain_4 <- samples_array[, 4, 1]

# Función para graficar una cadena
grafico_cadena <- function(valores, titulo) {
  ggplot(data.frame(iteracion = 1:length(valores), lambda = valores),
    aes(x = iteracion, y = lambda)) +
    geom_line(color = "royalblue") +
    labs(title = titulo, x = "iteración", y = expression("valor de " * lambda)) +
    theme_minimal() +
    theme(plot.title = element_text(hjust = 0.5))
}
```




'stat_bin()' using 'bins = 30'. Pick better value 'binwidth'.






Comparación entre la aproximación MCMC de la posterior de .
y la distribución Gamma(21,8)




```
# Densidades por cadena superpuestas
mcmc_dens_overlay(gp_sim, pars = "lambda") + ylab("density")
```




```
# Simulación corta para ilustrar convergencia pobre
gp_sim_short <- stan(model_code = gp_model,
  data = list(N = N, y = y, alpha = alpha, beta = beta),
  chains = 4, iter = 100 * 2, seed = 84735)

mcmc_trace(gp_sim_short, pars = "lambda")
```



```
mcmc_dens_overlay(gp_sim_short, pars = "lambda")
```




```
# Diagnósticos: tamaño efectivo, R-hat y autocorrelación  
neff_ratio(gp_sim, pars = c("lambda"))
```

```
## [1] 0.3802014
```

```
rhat(gp_sim, pars = "lambda")
```

```
## [1] 1.000029
```

```
mcmc_acf(gp_sim, pars = "lambda")
```



Condiciones iniciales para el capítulo 7

7.9.2 Práctica: Simulación Normal-Normal

En el siguiente conjunto de ejercicios, volvemos al modelo bayesiano del apartado (7.1):

$$Y \mid \mu \sim N(\mu, 0.75^2), \quad \mu \sim N(0, 1^2)$$

Supongamos que observamos $Y = 6.25$ y deseamos construir una simulación de Metropolis–Hastings del modelo posterior correspondiente para λ

Ejercicio 7.9 (Una iteración con un modelo de propuesta Uniforme)

La función `one_mh_iteration()` del texto utiliza un modelo de propuesta Uniforme:

$$\mu' \mid \mu \sim \text{Unif}(\mu - w, \mu + w)$$

con ancho $w=1$.

Partiendo de un valor actual de $\mu = 3$ y utilizando `set.seed(1)`, ejecuta el siguiente código y comenta sobre los valores retornados de `proposal`, `alpha`, y `next_stop`:

```
one_mh_iteration(w = 0.01, current = 3)
one_mh_iteration(w = 0.5, current = 3)
one_mh_iteration(w = 1, current = 3)
one_mh_iteration(w = 3, current = 3)
```

Primero seteamos la semilla en 1 y aplicamos la función `one_mh_iteration()` al valor inicial $\mu = 3$ con un ancho de $w = 0.01$.

proposal	alpha	next_stop
3.0026	1	3.0026

Con nuestros primeros valores, el algoritmo partió de $\mu = 3$ y, dado que el ancho era muy pequeño ($w = 0.01$), la propuesta resultó ser apenas distinta: $\mu' = 3.0026$. Al comparar la plausibilidad del valor actual y de la propuesta bajo la posterior, ambas resultaron prácticamente iguales, de modo que la razón de aceptación alcanzó el valor máximo posible, $\alpha = 1$. Eso implica que la propuesta se acepta sin ninguna duda, y por lo tanto la cadena se mueve al nuevo valor, quedando en $\mu = 3.0026$. Esto tiene lógica porque, al ser la propuesta muy cercana al valor actual, tanto la prior como la verosimilitud cambian mínimamente, lo que hace que la posterior apenas varíe y, por ende, la aceptación sea prácticamente segura.

Ahora aplicamos la función `one_mh_iteration()` al mismo valor inicial $\mu = 3$, pero aumentando el ancho a $w = 0.5$.

proposal	alpha	next_stop
2.98	0.95	2.98

A diferencia de la iteración anterior con $w = 0.01$, donde la propuesta estaba prácticamente pegada al valor actual, esta vez la propuesta $\mu' = 2.98$ se aleja un poco más de $\mu = 3$. Como resultado, la plausibilidad bajo la posterior cambia un poco más, y la razón de aceptación $\alpha = 0.95$ ya no es 1, aunque sigue siendo alta. Esto significa que la propuesta se acepta con una probabilidad cercana a 1, lo que refleja que la cadena puede moverse pasos más grandes cuando el ancho es mayor. La lógica detrás de esto es permitirnos explorar un rango más amplio alrededor del valor actual, la cadena puede realizar saltos más amplios, manteniendo el equilibrio entre explorar nuevas regiones y quedarse en zonas de alta probabilidad, lo que nos asegura una buena exploración del espacio posterior.

A continuación, usamos `one_mh_iteration()` con el mismo valor inicial $\mu = 3$, pero aumentando aún más el ancho a $w = 1$.

proposal	alpha	next_stop
2.87	0.67	3

En comparación con las iteraciones anteriores, la propuesta $\mu' = 2.87$ se aleja bastante del valor actual. Esto provoca un cambio más marcado en la plausibilidad bajo la posterior, y la razón de aceptación cae a $\alpha = 0.67$. Como resultado, la propuesta no se acepta en esta ocasión, y la cadena permanece en $\mu = 3$. La lógica de este comportamiento es consistente con el algoritmo, al ampliar el rango de propuestas, se permiten saltos más grandes que exploran más el espacio, pero también aumenta la probabilidad de proponer valores menos compatibles con los datos y la prior. Así, el algoritmo equilibra exploración y aceptación, evitando moverse automáticamente a cualquier propuesta que no sea suficientemente plausible.

Finalmente, aplicamos `one_mh_iteration()` con el valor inicial $\mu = 3$ y un ancho aún mayor, $w = 3$.

proposal	alpha	next_stop
2.63	0.29	3

En esta iteración, la propuesta $\mu' = 2.63$ se aleja significativamente del valor actual, mucho más que en las pruebas anteriores. Esto provoca un cambio considerable en la plausibilidad de la posterior, y la razón de aceptación disminuye notablemente a $\alpha = 0.29$. Como resultado, la propuesta no se acepta, y la cadena permanece en $\mu = 3$. La lógica detrás de este comportamiento es coherente con el diseño del algoritmo: al generar propuestas que se alejan demasiado del valor actual, la probabilidad de aceptar un valor menos compatible con los datos y la prior disminuye, lo que evita saltos grandes que podrían llevar a regiones de baja probabilidad.

En pocas palabras, con w pequeño la cadena avanza despacio y casi siempre acepta, mientras que con w más grande las propuestas se alejan más y se aceptan menos. Elegir w es un equilibrio entre pasos seguros y explorar más el espacio.

Ejercicio 7.10 (Un recorrido completo con un modelo de propuesta Uniforme)

Implementa la función de Metropolis-Hastings `mh_tour()` definida en la Sección 7.3 para construir recorridos de μ bajo cada uno de los siguientes escenarios. Construye gráficos de trazas e histogramas para cada recorrido:

1. 50 iteraciones, $w = 50$

